

M3SOL025 - Paradigmes d'évaluation du traitement automatique des langues TAL

Gaël Lejeune gael.lejeune@sorbonne-universite.fr

2025-2026

STIH EA 4509, CERES, Sorbonne Université

Objectifs du jour

- Mesures de base en classification en TAL : précision, rappel, F-mesure (F_1 , F_β)

Objectifs du jour

- Mesures de base en classification en TAL : précision, rappel, F-mesure (F_1 , F_β)
- Mesures de base en RI/ordonnancement : Précision@k, Rappel@k, AP, MAP, DCG / **nDCG**

Objectifs du jour

- Mesures de base en classification en TAL : précision, rappel, F-mesure (F_1 , F_β)
- Mesures de base en RI/ordonnancement : Précision@k, Rappel@k, AP, MAP, DCG / **nDCG**
- Comprendre l'intérêt **Montrer les limites** de chaque métrique
- Lien : du binaire (instance-level) au graduel et ordonné (ranking)

Mesures traditionnelles en TAL/classification

Matrice de confusion (binaire)

	Prédit +	Prédit -
Réel +	VP	FN
Réel -	FP	VN

$$P = \frac{VP}{VP+FP}, \quad R = \frac{VP}{VP+FN}, \quad F_1 = 2 \frac{PR}{P+R}.$$

Limites (NLP)

- **Accuracy** trompeuse sur classes déséquilibrées (F1 préférable).
- **Seuil** $\Rightarrow$ compromis précision/rappel (même F1, profils d'erreurs différents).

Limites (NLP)

- **Accuracy** trompeuse sur classes déséquilibrées (F1 préférable).
- **Seuil** $\Rightarrow$ compromis précision/rappel (même F1, profils d'erreurs différents).
- F1 ignore les **VN** et le **coût** asymétrique des erreurs (parfois préférer F_β).

- **Accuracy** trompeuse sur classes déséquilibrées (F1 préférable).
- **Seuil** $\Rightarrow$ compromis précision/rappel (même F1, profils d'erreurs différents).
- F1 ignore les **VN** et le **coût** asymétrique des erreurs (parfois préférer F_β).
- **Macro** vs **Micro** : interprétations différentes.

Mesures en Recherche d'Information (RI)

Sortie = **classement** + **pertinence** (binaire ou graduelle). Position $\Rightarrow$ utilité.


- **P@k**, **R@k** : qualité sur le top- k
- **AP** (binaire) et **MAP** (moyenne multi-requêtes)
- **DCG/nDCG** : pertinence graduelle + *discount* par rang

Limites (RI)


- P@k sensible au **cutoff** k
- R@k dépend du **pool** de pertinents (jugements incomplets)
- MAP masque la **variance** entre requêtes
- nDCG sensible au **gain** (linéaire vs exponentiel) et au **cutoff**

Passer par le visuel

Courbe PR (classification)




Courbe ROC (classification)




Multiclasse : erreurs et déséquilibre

Matrice de confusion — 3 classes (heatmap)



nDCG : gain linéaire vs exponentiel



nDCG — interprétation du gain linéaire vs exponentiel

$$\text{DCG}@k = \sum_{i=1}^k \frac{g_i}{\log_2(i+1)} \quad \text{où } g_i = \text{gain}(\text{rel}_i)$$

Deux choix possibles pour la fonction de gain

- **Gain linéaire** : $g(\text{rel}) = \text{rel} \Rightarrow$ chaque niveau de pertinence ajoute une valeur proportionnelle.
- **Gain exponentiel** : $g(\text{rel}) = 2^{\text{rel}} - 1 \Rightarrow$ les documents très pertinents comptent beaucoup plus.

Niveau de pertinence	0	1	2	3
Gain linéaire	0	1	2	3
Gain exponentiel	0	1	3	7

nDCG — interprétation du gain linéaire vs exponentiel

Niveau de pertinence	0	1	2	3
Gain linéaire	0	1	2	3
Gain exponentiel	0	1	3	7

Interprétation :

- Le **gain linéaire** favorise la régularité : plusieurs résultats pertinents suffisent.
- Le **gain exponentiel** surpondère les très pertinents : utile pour les classements courts (web search).

Synthèse

Quel indicateur pour quel usage ?

- **Filtrage strict** : précision élevée (F_β , $\beta < 1$), PR-curve.

Quel indicateur pour quel usage ?

- **Filtrage strict** : précision élevée (F_β , $\beta < 1$), PR-curve.
- **Veille signaux faibles** : rappel prioritaire (F_β , $\beta > 1$), AP (classification).

Quel indicateur pour quel usage ?

- **Filtrage strict** : précision élevée (F_β , $\beta < 1$), PR-curve.
- **Veille signaux faibles** : rappel prioritaire (F_β , $\beta > 1$), AP (classification).
- **Recherche Info** : $P@k$, $nDCG@k$ (petits k), Mean Average Precision.