

# M3SOL025 - Comparer des Textes

---

Gaël Lejeune   [gael.lejeune@sorbonne-universite.fr](mailto:gael.lejeune@sorbonne-universite.fr)

2025-2026

STIH EA 4509, CERES, Sorbonne Université

# M3SOL025 - Comparer des Textes

---

Gaël Lejeune   [gael.lejeune@sorbonne-universite.fr](mailto:gael.lejeune@sorbonne-universite.fr)

2025-2026

STIH EA 4509, CERES, Sorbonne Université

- Comprendre pourquoi on mesure la distance / similarité entre textes.
- Connaître les principales tâches : traduction, résumé, OCR/HTR, Web scraping...
- Découvrir plusieurs familles de métriques :
  - Distances caractère / mot (CER, WER, Levenshtein)
  - Basées sur les n-grammes (BLEU, ROUGE)
  - Basées sur des vecteurs (cosinus, embeddings)
- Manipuler ces métriques dans un notebook Python.

# Motivation et tâches

---

# Pourquoi mesurer la distance entre textes ?

- Évaluer des systèmes automatiques :
  - Traduction automatique (MT)
  - Résumé automatique
  - OCR/HTR (reconnaissance de texte)
  - Extraction Web / Web scraping
  - Génération de texte (LLM, chatbots)
- Détecter des similarités :
  - Plagiat
  - Doublons de documents
  - Clustering / classification

- **Traduction automatique** : comparer la traduction générée à une ou plusieurs références humaines.
- **Résumé automatique** : comparer un résumé généré au résumé humain (couverture de l'information).
- **OCR/HTR** : comparer le texte reconnu à la transcription de référence.
- **Web scraping** : vérifier que le texte extrait correspond bien à la source.
- **Détection de similarité/plagiat** : mesurer la proximité de deux documents.

## **Distances sur la chaîne de caractères**

---

# Distance de Levenshtein

- Mesure le **nombre minimal d'opérations d'édition** pour transformer une chaîne A en B :
  - insertion
  - suppression
  - substitution
- Peut être normalisée pour donner un score dans  $[0,1]$ .

## Exemple (simplifié) :

- Référence : chat
- Hypothèse : chats
- Distance de Levenshtein = 1 (insertion de s)



# CER : Character Error Rate

- Utilisé pour l'évaluation de l'OCR/HTR, ASR...
- Définition :

$$CER = \frac{S + D + I}{N}$$

où :

- $S$  = nombre de substitutions
- $D$  = nombre de suppressions (deletions)
- $I$  = nombre d'insertions
- $N$  = nombre de caractères dans la référence

## Exemple illustré :

Référence : bonjour

Hypothèse : bonjur

- $o \rightarrow u$  : 1 substitution
- $N = 7$  caractères
- $CER = \frac{1}{7} \approx 0,14$

# WER : Word Error Rate

- Même principe que CER mais au niveau des mots.
- Définition :

$$WER = \frac{S + D + I}{N}$$

où  $N$  est le nombre de mots de la référence.

## Exemple illustré :

Référence : je vais à l'école

Hypothèse : je vais à école

- Suppression de l' :  $D = 1$
- $N = 4$  mots
- $WER = \frac{1}{4} = 0,25$

# Métriques à base de n-grammes

---

# BLEU : Bilingual Evaluation Understudy

- Utilisé principalement pour la **traduction automatique**.
- Compare les n-grammes (1-gram, 2-gram, etc.) de la sortie modèle à ceux de la traduction de référence.
- Idée : plus le chevauchement de n-grammes est grand, meilleure est la traduction.
- Intègre une **brevity penalty** pour éviter les traductions trop courtes.

# Exemple simplifié de BLEU (unigrammes)

## Référence :

le chat dort sur le canapé

## Hypothèse 1 :

le chat dort

## Hypothèse 2 :

le chien court dans le jardin

- Hypothèse 1 : beaucoup d'unigrammes en commun (le, chat, dort)
- Hypothèse 2 : très peu d'unigrammes en commun (le seulement)
- $\text{BLEU}(H1) \gg \text{BLEU}(H2)$

- ROUGE-N : chevauchement de n-grammes entre le résumé généré et le résumé de référence.
- ROUGE-L : longueur de la plus longue sous-séquence commune (LCS).
- Utilisé pour évaluer la **couverture d'information** d'un résumé.

## Exemple (idée) :

- Référence : mentionne 5 faits importants.
- Résumé système : en couvre seulement 3.
- ROUGE reflète ce niveau de rappel.

## Similarité vectorielle (cosinus)

---

# Similarité cosinus (TF-IDF, embeddings)

- Représenter chaque texte comme un **vecteur** :
  - sac de mots (bag-of-words)
  - TF-IDF
  - vecteurs sémantiques (BERT, SBERT, etc.)
- Mesurer l'angle entre les deux vecteurs : similarité cosinus.

$$\cos(\theta) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|}$$

- 1 : textes très proches
- 0 : textes orthogonaux (sans rapport)
- -1 : opposés (cas rare en pratique)



## Exemple intuitif : similarité cosinus

**Texte A** : Le chat dort sur le canapé.

**Texte B** : Le canapé est occupé par un chat qui dort.

**Texte C** : La voiture roule vite sur l'autoroute.

- A et B : vocabulaire similaire, même thème  $\Rightarrow$  cosinus élevé.
- A et C : vocabulaire très différent  $\Rightarrow$  cosinus faible.

### Application :

- détection de doublons
- comparaison de textes scrappés
- recherche d'information (retrieval)

## Résumé et comparaison

---

## Résumé : quelle métrique pour quelle tâche ?

| Tâche                | Métriques typiques                   |
|----------------------|--------------------------------------|
| Traduction           | BLEU, METEOR, TER, COMET             |
| Résumé               | ROUGE-N, ROUGE-L, BERTScore          |
| OCR/HTR              | CER, WER, Levenshtein                |
| Web scraping         | Levenshtein, Jaccard, cosinus TF-IDF |
| Similarité / plagiat | Cosinus TF-IDF, embeddings           |

# Limites des métriques automatiques

- BLEU/ROUGE : sensibles à la forme lexicale, pas toujours au sens profond.
- Cosinus TF-IDF : ne capture pas bien la synonymie ou la paraphrase.
- Les métriques automatiques ne remplacent pas l'évaluation humaine :
  - cohérence globale
  - factualité (hallucinations)
  - style, registre
- Bonne pratique : **combiner plusieurs métriques** + évaluation humaine.

## Travaux pratiques (notebook Python)

- Calculer CER/WER sur des sorties OCR.
- Calculer BLEU pour des traductions.
- Calculer ROUGE pour des résumés.
- Calculer la similarité cosinus (TF-IDF) pour comparer deux pages Web scrappées.
- (Optionnel) Tester des embeddings pour la similarité sémantique.

**Voir le notebook associé pour les exemples de code.**