

En finir avec les pré-traitements ?

Gaël Lejeune (gael.lejeune@sorbonne-universite.fr)

12 Décembre 2024

Sorbonne Université

**Les pré-traitements en TAL,
what is it good for ?**

Understanding Preprocessing

Preprocessing is a critical step in NLP that involves cleaning and preparing text data for analysis. It includes several tasks such as tokenization, removing stop words, stemming, lemmatization, and more. These tasks help in reducing the noise in the data, making it more manageable and meaningful for analysis.

Text preprocessing is an essential step in **natural language processing** (NLP) that involves cleaning and transforming unstructured text data to prepare it for analysis. It includes **tokenization, stemming, lemmatization, stop-word removal, and part-of-speech tagging**. In this article, we will introduce the basics of text preprocessing and provide **Python** code examples to illustrate how to implement these tasks using the **NLTK library**. By the end of the article, readers will better understand how to prepare text data for NLP tasks.

Machine Learning heavily relies on the quality of the data fed into it, and thus, data preprocessing plays a crucial role in ensuring the accuracy and efficiency of the model. In this article, we will discuss the main text preprocessing techniques used in NLP.

1. Text Cleaning

In this step, we will perform fundamental actions to clean the text. These actions involve transforming all the text to lowercase, eliminating characters that do not qualify as words or whitespace, as well as removing any numerical digits present.

I. Converting to lowercase

Here is a comprehensive list of common text preprocessing:

1. Text lowercasing
2. Tokenization
3. Stop-word removal
4. Handling Numerical values
5. Handling Special characters
6. Whitespace stripping
7. Lemmatization/Stemming

Quelle est la différence

- Les pré-traitements sont anodins (mais obligatoires?)
- Les "traitements" sont plus nobles?

Quelle est la différence

- Les pré-traitements sont anodins (mais obligatoires?)
- Les "traitements" sont plus nobles?
- Lesquels sont documentés et justifiés

Quelle est la différence

- Les pré-traitements sont anodins (mais obligatoires ?)
- Les "traitements" sont plus nobles ?
- Lesquels sont documentés et justifiés

Les pré-traitements sont en fait des traitements à part entière puisqu'ils ont un impact non nul sur les opérations subséquentes réalisées
[Millour, 2020]

Traitements ou pré-traitements

Quelle est la différence

- Les pré-traitements sont anodins (mais obligatoires?)
- Les "traitements" sont plus nobles?
- Lesquels sont documentés et justifiés

Les pré-traitements sont en fait des traitements à part entière puisqu'ils ont un impact non nul sur les opérations subséquentes réalisées
[Millour, 2020]

D'un point de vue de conception :

- Ils prennent du temps
- Focalisent-ils l'attention sur les bons problèmes?

Traitements ou pré-traitements

Quelle est la différence

- Les pré-traitements sont anodins (mais obligatoires ?)
- Les "traitements" sont plus nobles ?
- Lesquels sont documentés et justifiés

Les pré-traitements sont en fait des traitements à part entière puisqu'ils ont un impact non nul sur les opérations subséquentes réalisées
[Millour, 2020]

D'un point de vue de conception :

- Ils prennent du temps
- Focalisent-ils l'attention sur les bons problèmes ?
- Améliorent-ils les résultats ?

Traitements ou pré-traitements

Quelle est la différence

- Les pré-traitements sont anodins (mais obligatoires ?)
- Les "traitements" sont plus nobles ?
- Lesquels sont documentés et justifiés

Les pré-traitements sont en fait des traitements à part entière puisqu'ils ont un impact non nul sur les opérations subséquentes réalisées
[Millour, 2020]

D'un point de vue de conception :

- Ils prennent du temps
- Focalisent-ils l'attention sur les bons problèmes ?
- Améliorent-ils les résultats ?

De quels pré-traitements parle-t-on ?

In the literature there is no convention adopted, and each work tests some preprocessing techniques rather than others.

- Lowercase letters.
- Spelling Correction.

De quels pré-traitements parle-t-on ?

In the literature there is no convention adopted, and each work tests some preprocessing techniques rather than others.

- Lowercase letters.
- Spelling Correction.
- Removing HTML tags/ URLs.

De quels pré-traitements parle-t-on ?

In the literature there is no convention adopted, and each work tests some preprocessing techniques rather than others.

- Lowercase letters.
- Spelling Correction.
- Removing HTML tags/ URLs.
- Removing punctuation.
- Removing stop words

De quels pré-traitements parle-t-on ?

In the literature there is no convention adopted, and each work tests some preprocessing techniques rather than others.

- Lowercase letters.
- Spelling Correction.
- Removing HTML tags/ URLs.
- Removing punctuation.
- Removing stop words
- Removing Emojies

De quels pré-traitements parle-t-on ?

In the literature there is no convention adopted, and each work tests some preprocessing techniques rather than others.

- Lowercase letters.
- Spelling Correction.
- Removing HTML tags/ URLs.
- Removing punctuation.
- Removing stop words
- Removing Emojies
- Tokenization
- Stemming
- Lemmatization

De quels pré-traitements parle-t-on ?

In the literature there is no convention adopted, and each work tests some preprocessing techniques rather than others.


- Lowercase letters.
- Spelling Correction.
- Removing HTML tags/ URLs.
- Removing punctuation.
- Removing stop words
- Removing Emojies
- Tokenization
- Stemming
- Lemmatization

How good is your tokenizer ? on the monolingual performance of multilingual language models (Rust et al. 2020)

Stemming impact on arabic text categorization performance : A survey (Al Anzi 2015)

Is text preprocessing still worth the time ? A comparative survey on the influence of popular preprocessing methods ... [Siino et al., 2024]

Etat des lieux plus précis (Siino et al.)



DON	Do Nothing	SCO	Spelling Correction
RNS	Replace Noise	POS	Part-of-Speech Tagging
RSA	Replace Slang/Abbreviations	LEM	Lemmatization
RCT	Replace Contraction	STM	Stemming
RRP	Remove Repeated Punctuation	ECR	Remove Elongation
RPT	Removing Punctuation	EMO	Emoticon Handling
RNB	Remove Numbers	NEG	Negation Handling
LOW	Lowercasing	WSG	Word Segmentation
RSW	Remove Stop Words		(sometrendingtopic)

Polarité Critiques en (Siino et al.)

Preprocessing	IMDB					
	RoBERTa	XLNet	ELECTRA	ANN	CNN	BiLSTM
DON (D)	0.884 ± 0.00	0.885 ± 0.00	0.888 ± 0.00	0.835 ± 0.01	0.856 ± 0.00	0.847 ± 0.00
LOW (L)	0.877 ± 0.00	0.881 ± 0.01	0.895 ± 0.04	0.842 ± 0.01	0.857 ± 0.00	0.843 ± 0.01
RSW (R)	0.885 ± 0.00	0.886 ± 0.00	0.890 ± 0.07	0.840 ± 0.01	0.855 ± 0.00	0.843 ± 0.01
STM (S)	0.853 ± 0.00	0.852 ± 0.03	0.857 ± 0.05	0.834 ± 0.01	0.856 ± 0.00	0.837 ± 0.02
(L)→(R)	0.875 ± 0.04	0.878 ± 0.01	0.888 ± 0.01	0.840 ± 0.01	0.854 ± 0.00	0.844 ± 0.01
(L)→(S)	0.849 ± 0.00	0.847 ± 0.01	0.860 ± 0.03	0.845 ± 0.00	0.855 ± 0.00	0.845 ± 0.02
(R)→(L)	0.876 ± 0.04	0.874 ± 0.00	0.890 ± 0.01	0.844 ± 0.01	0.855 ± 0.00	0.847 ± 0.01
(R)→(S)	0.826 ± 0.02	0.823 ± 0.32	0.832 ± 0.02	0.839 ± 0.00	0.855 ± 0.00	0.844 ± 0.02
(S)→(L)	0.849 ± 0.00	0.845 ± 0.03	0.864 ± 0.01	0.839 ± 0.00	0.854 ± 0.00	0.840 ± 0.01
(S)→(R)	0.798 ± 0.07	0.817 ± 0.01	0.832 ± 0.01	0.843 ± 0.01	0.854 ± 0.00	0.843 ± 0.01
(L)→(S)→(R)	0.806 ± 0.04	0.782 ± 0.12	0.824 ± 0.01	0.837 ± 0.01	0.855 ± 0.00	0.839 ± 0.34
(L)→(R)→(S)	0.838 ± 0.34	0.820 ± 0.02	0.837 ± 0.04	0.842 ± 0.01	0.854 ± 0.00	0.845 ± 0.00
(S)→(L)→(R)	0.812 ± 0.01	0.645 ± 0.18	0.818 ± 0.02	0.840 ± 0.01	0.856 ± 0.00	0.845 ± 0.01
(S)→(R)→(L)	0.818 ± 0.02	0.820 ± 0.05	0.837 ± 0.01	0.843 ± 0.01	0.853 ± 0.00	0.839 ± 0.01
(R)→(L)→(S)	0.829 ± 0.03	0.837 ± 0.17	0.825 ± 0.05	0.838 ± 0.01	0.855 ± 0.00	0.848 ± 0.01
(R)→(S)→(L)	0.806 ± 0.03	0.822 ± 0.07	0.848 ± 0.01	0.838 ± 0.01	0.857 ± 0.00	0.838 ± 0.34

Figure 1 – Médiane de l'exactitude (*accuracy*) sur 5 runs + diffmax. Pour chaque modèle le meilleur résultat est en gras, le pire en rouge

Etat des lieux plus précis (en) (Siino et al.)

IMDB : Polarité Critiques, PCL : Langage Condescendant Presse

FNS : AA Fake News, 20N : Catégorisation Forums

Preprocessing	IMDB			PCL			FNS			20N		
	NB	SVM	LR	NB	SVM	LR	NB	SVM	LR	NB	SVM	LR
DON	0.767	0.835	0.798	0.726	0.729	0.693	0.685	0.630	0.640	0.040	0.160	0.140
LOW	0.771	0.831	0.801	0.736	0.696	0.668	0.695	0.665	0.650	0.040	0.140	0.100
RSW	0.787	0.831	0.833	0.719	0.651	0.686	0.705	0.715	0.660	0.020	0.100	0.060
STM	0.741	0.794	0.773	0.683	0.678	0.691	0.675	0.645	0.640	0.040	0.160	0.080
LOW → RSW	0.787	0.828	0.833	0.706	0.671	0.683	0.720	0.690	0.680	0.040	0.140	0.040
LOW → STM	0.725	0.803	0.770	0.678	0.668	0.688	0.700	0.665	0.615	0.040	0.120	0.100
RSW → LOW	0.789	0.835	0.820	0.721	0.663	0.691	0.725	0.690	0.675	0.040	0.120	0.020
RSW → STM	0.780	0.794	0.811	0.671	0.641	0.656	0.680	0.695	0.675	0.020	0.160	0.100
STM → LOW	0.725	0.803	0.800	0.678	0.668	0.673	0.700	0.665	0.635	0.040	0.120	0.060
STM → RSW	0.775	0.790	0.821	0.681	0.641	0.646	0.675	0.675	0.670	0.020	0.140	0.120
LOW → STM → RSW	0.750	0.799	0.820	0.678	0.623	0.648	0.695	0.680	0.645	0.040	0.140	0.080
LOW → RSW → STM	0.747	0.794	0.821	0.668	0.636	0.661	0.700	0.685	0.650	0.040	0.140	0.080
STM → LOW → RSW	0.749	0.797	0.814	0.678	0.623	0.661	0.690	0.675	0.645	0.040	0.140	0.080
STM → RSW → LOW	0.749	0.797	0.814	0.678	0.623	0.661	0.690	0.685	0.655	0.040	0.140	0.080
RSW → LOW → STM	0.757	0.797	0.807	0.673	0.623	0.678	0.720	0.670	0.655	0.040	0.140	0.120
RSW → STM	0.756	0.797	0.803	0.673	0.623	0.651	0.720	0.675	0.685	0.040	0.160	0.080

Langage Figuratif Tweets fr (Choi 2020)

	Logistic Regression		Decision Tree		MNB		KNN		Random Forest	
	Count	Tfidf	Count	Tfidf	Count	Tfidf	Count	Tfidf	Count	Tfidf
DON	50.20	52.03	50.41	42.89	51.42	52.24	38.82	45.73	53.25	51.22
RPT	50.41	52.64	48.37	44.72	50.81	51.63	38.21	45.53	53.05	52.64
RSW	52.24	53.86	45.93	44.11	51.22	52.24	37.40	44.31	50.00	50.20
ACC	49.59	52.64	49.39	43.29	51.02	52.03	35.16	45.53	52.44	52.03
URL	47.56	47.36	39.43	39.43	50.20	50.61	34.35	41.46	45.53	44.51
LEM	50.20	54.07	49.19	44.72	52.24	53.25	39.02	45.53	50.41	51.63
STM	51.63	53.86	48.37	45.93	52.03	52.44	38.41	46.75	52.44	51.42

Table 1 – Exactitude moyenne (En bleu, le meilleur résultat, en rouge le plus faible résultat pour chaque classifieur)

Langage Figuratif Tweets fr (Choi 2020)

Classifieur	Count Vectorizer	Macro f-mesure	Tfidf Vectorizer	Macro f-mesure
Logistic Regression	LEM, RSW	53.53	LEM, RSW, RAC	54.35
Decision Tree	RPT, accents, RAC RSW	49.59	RAC, RPT	48.58
MNB	LEM, RSW, RAC	54.59	LEM, RSW, RAC	55.89
KNN	RAC, RSW, RPT	38.20	RAC, RSW	47.35
Random Forest	LEM, RSW, accents, RAC	51.38	LEM, RSW, accents, RAC	53.25

Table 2 – Meilleurs résultats en macro f-mesure (En bleu, le meilleur résultat, en rouge le plus faible résultat. Meilleur résultat du DEFT2017 65%)

Les combinaisons de pré-traitement

A comparative evaluation of pre-processing techniques and their interactions for twitter sentiment analysis [Symeonidis et al., 2018]

Les combinaisons de pré-traitement

A comparative evaluation of pre-processing techniques and their interactions for twitter sentiment analysis [Symeonidis et al., 2018]

Influence des pré-traitements sur la classification de textes - Application à la classification de tweets selon leur polarité (Heesoo Choi 2020, mémoire de master)

Les combinaisons de pré-traitement

A comparative evaluation of pre-processing techniques and their interactions for twitter sentiment analysis [Symeonidis et al., 2018]

Influence des pré-traitements sur la classification de textes - Application à la classification de tweets selon leur polarité (Heesoo Choi 2020, mémoire de master)

Qu'apprend-on

- Deux pré-traitements peuvent mal interagir
- Le gain de performance est asymptotique

Les combinaisons de pré-traitement

A comparative evaluation of pre-processing techniques and their interactions for twitter sentiment analysis [Symeonidis et al., 2018]

Influence des pré-traitements sur la classification de textes - Application à la classification de tweets selon leur polarité (Heesoo Choi 2020, mémoire de master)

Qu'apprend-on

- Deux pré-traitements peuvent mal interagir
- Le gain de performance est asymptotique
- Le cocktail ne fonctionne pas quel que soit :
 - la tâche
 - le type de textes
 - le classifieur
 - le modèle de langue



Millour, A. (2020).

Myriadisation de ressources linguistiques pour le TA de langues non standardisées.
PhD thesis, Sorbonne Université, France.



Siino, M., Tinnirello, I., and La Cascia, M. (2024).

Is text preprocessing still worth the time ? a comparative survey on the influence of popular preprocessing methods on transformers and traditional classifiers.
Information Systems, 121 :102342.



Symeonidis, S., Effrosynidis, D., and Arampatzis, A. (2018).

A comparative evaluation of pre-processing techniques and their interactions for twitter sentiment analysis.
Expert Systems with Applications, 110 :298–310.